

MiniCPM-o 4.5

昇腾 vLLM-Omni 高性能推理优化报告

HiDevLab 单卡 910C 分配 · 流式语音生成 · 单变量 A/B · 三档并发矩阵

子赛道	vLLM-Omni 推理优化	模型	MiniCPM-o 4.5
运行环境	910C 分配; npu-smi=Ascend910	框架提交	4a0a48177862...
候选配置	Token2Wav steps: 10 -> 9	回退配置	官方 challenge 基线副本

核心结论：在相同 c1/n32 输入和计时口径下，两次 steps=9 候选复测的 Mean RTF 降低 5.58%-6.42%，Mean TTTP 降低 4.71%-5.44%，E2E 降低 5.28%-6.08%，吞吐提升 5.57%-6.46%；32 条代理 WER 与基线完全一致。				
--	--	--	--	--

TTFT 降幅 1.41-1.77% 两次候选复测	TTTP 降幅 4.71-5.44% 两次候选复测	RTF 降幅 5.58-6.42% 核心指标	E2E 降幅 5.28-6.08% 整体耗时	吞吐增幅 5.57-6.46% req/s
---------------------------------	---------------------------------	------------------------------	------------------------------	-----------------------------

证据边界：性能 JSON 与环境快照来自报告运行；npu-smi 只显示通用设备名 Ascend910，不能独立认证具体子型号。WER/ASV 均为非官方配对代理，主办方正式精度评测前不宣称官方精度通过。

1. 优化方法与同机 A/B

保留可读官方 challenge 配置作为基线，仅在 connector extra 中增加 token2wav_n_timesteps: 9，其默认值为 10。减少一次 flow-matching 迭代会改变声学生成数值路径，因此必须同时检查性能、WER 和说话人相似度。

本次同机 A/B 口径

同一份 HiDevLab 910C 分配、完整 Seed-TTS English、seed=0 shuffle、并发 1、2 个完整语音 warmup 和 32 个计时请求。基线与两次候选均为 32/32、32/32、32/32 成功，失败数均为 0。

本地定义：TTFT 为请求到首个有效文本 token；TTFP 为请求到首个音频包；RTF 为音频生成计算耗时除以音频时长；E2E 为请求到完整响应结束；吞吐为完成请求数除以矩阵墙钟时间（req/s）。官方起止点以主办方脚本为准。

指标	基线 steps=10	steps=9 run 1	变化	steps=9 run 2	变化
Mean TTFT	318.937 ms	314.445 ms	-1.41%	313.285 ms	-1.77%
Mean TTFP	1021.933 ms	973.763 ms	-4.71%	966.361 ms	-5.44%
Mean RTF	0.471207	0.444927	-5.58%	0.440935	-6.42%
Mean E2E	2000.559 ms	1894.958 ms	-5.28%	1878.938 ms	-6.08%
吞吐 (req/s)	0.499764	0.527579	+5.57%	0.532074	+6.46%

steps=9 第二次复测相对同机基线的改善



两次候选复测之间，TTFT、TTFP、RTF、E2E 和吞吐的相对差异均小于 1%，说明候选方向一致。基线只运行一次，因此不能估计基线波动或宣称统计显著。这里的收益只针对相同输入、配置与计时口径，不与冷启动或 4 请求 smoke 混用。

2. 三档请求矩阵、尾延迟与高并发权衡

本地 harness 进一步跑完与赛事配置对齐请求数、并发数和主要参数的 c1/n32、c4/n64、c8/n128 矩阵。三档共 224 个计时请求全部成功、0 失败；这只说明请求级完成，不等同主办方正式 pytest harness 或尾延迟稳定。

档位	成功/失败	TTFT	TTFP	RTF	E2E	吞吐 req/s
c1/n32	32/0	313.285 ms	966.361 ms	0.440935	1878.938 ms	0.532074
c4/n64	64/0	494.024 ms	3279.353 ms	1.427453	6034.233 ms	0.654534
c8/n128	128/0	551.120 ms	3646.525 ms	2.115514	9613.281 ms	0.820408

Median / p99 尾延迟

档位	Med TTFP	p99 TTFP	Med RTF	p99 RTF	Med E2E	p99 E2E
c1/n32	0.965s	1.100s	0.434	0.596	1.873s	2.507s
c4/n64	2.126s	21.346s	1.117	7.127	4.947s	22.967s
c8/n128	3.352s	14.036s	1.968	4.557	8.921s	21.174s

c4/n64 的 p99 TTFP/E2E 达到 21.346s/22.967s，c8/n128 达到 14.036s/21.174s。成功率不能掩盖这一长尾；不同样本量下也不应把 c4 与 c8 的 p99 大小直接解释为并发越高反而越稳定。

相对赛事配置内参考值的定位

档位	TTFT vs ref	TTFP vs ref	RTF vs ref	E2E vs ref	吞吐 vs ref
c1/n32	-5.99%	-2.04%	-0.31%	+1.17%	-1.16%
c4/n64	-7.46%	-3.86%	-9.28%	-8.58%	+8.33%
c8/n128	+0.69%	+8.76%	-8.12%	-8.01%	+8.71%

负数表示时延或 RTF 更低，吞吐列正数表示更高。官方参考值不是本机同次运行，因此只用于矩阵级定位，不能替代第 1 节同机 A/B。c8/n128 的 TTFP 高 8.76%，说明高并发存在首包与总体吞吐的明确权衡。

已淘汰方案：codec_chunk_frames 25 -> 20。虽然 TTFP 改善 6.66%，但 RTF 恶化 6.03%、E2E 恶化 6.23%、吞吐下降 5.86%，不作为最终默认配置。

尚未覆盖：官方 single-chunk latency 分布、NPU/AICore/HBM 利用率采样、长时间稳定性和多 session 调度。当前 JSON 不能支持这些结论。

3. 质量代理与精度边界

steps=9 少一次声学迭代，不能只看速度。对与性能测试相同的 32 条 Seed-TTS English 样本分别保存基线和候选完整 WAV，再执行配对 WER 与说话人相似度检查。

检查	基线	steps=9	结果
Whisper large-v3 proxy Mean WER	1.071238%	1.071238%	32 条归一化 WER 全部一致
未校准 ASV proxy Mean SIM	0.02345999	0.02296496	17 对提高，15 对降低
ASV paired delta	-	-0.00049502	95% CI [-0.00447, 0.00348]

ASV 配对统计

paired t-test p=0.801，Wilcoxon p=0.875。在这一未校准 CPU proxy 上，32 对的配对差异没有统计显著性；这不等于证明两个配置等价，也不构成 ASV 精度门禁。严格 v2 脚本将 checkpoint、源码、meta、seed/范围及 96 个输入 WAV 哈希绑定到运行指纹，并能拒绝旧进度文件。严格原始 JSON 已随包保存；validator 会核对固定指纹、源码与输入哈希、32/32 完成状态和代理计算质量门。

重要边界：WER 使用相同 large-v3 checkpoint 的 OpenAI Whisper 实现；ASV 使用相同 WavLM/ECAPA 代码和权重的 CPU 最小移植。两项结果均标记 official_protocol=false，不能替代主办方正式 WER/ASV，也不能将 CPU proxy 的绝对 SIM 与官方 ASV 门槛直接比较。

结果可审计性

项目	状态
原始性能 JSON	已保存，全部 completed == num_prompts 且 failed == 0
提交文件 SHA-256	RESULT_MANIFEST.sha256 + validate_submission.py 自动核验
配置变化	仅 token2wav_n_timesteps: 9，一键回退基线
严格 ASV v2 JSON	已随包保存；绑定固定指纹、96 个输入与 3 份源码哈希
环境快照	已保存 npu-smi、CANN/torch_npu/vLLM 版本、commit 与 pip-freeze
共享资源	/workspace/shared_assets 只读，未修改模型或数据集

4. 复现、提交与最终决定

候选服务启动

```
cd /workspace/user_data/minicpm-vllm-omni/submission
bash scripts/collect_env.sh
CONFIG="$PWD/configs/experiment_steps9.yaml" bash scripts/start_server.sh
```

第二终端执行 Demo、矩阵和自检

```
cd /workspace/user_data/minicpm-vllm-omni/submission
bash scripts/run_demo.sh
bash scripts/benchmark_matrix.sh
python3 scripts/validate_submission.py
```

run_demo.sh 会记录配置哈希、服务健康状态、NPU 信息，执行文本到流式语音请求，并校验 WAV 的 24 kHz 单声道格式、时长和 SHA-256。每次运行写入独立时间戳目录，避免与旧 Demo 文件混用。

最终采用决定

方案	决定	理由
官方基线	保留	可读、可回退，是所有同机 A/B 的共同基准
codec20	淘汰	核心 RTF、E2E 和吞吐同时退化
steps9	当前提交候选	两次候选方向一致；Whisper proxy WER 一致；未校准 ASV proxy 配对差异不显著

提交前仍需外部完成：录制实际可播放的 Demo 视频；在主办方最终环境运行正式 WER/ASV；正式赛事包补入完整服务日志；按平台最新要求核对文件命名、大小和截止时间。

参考与附件

赛事评测规范：<https://modelbest.feishu.cn/docx/U41vdXMmQo7tv3xW2p9c9uEanKe>
官方 benchmark 配置：https://github.com/vllm-project/vllm-omni/blob/4a0a4817/tests/dfx/perf/tests/test_minicpmo_4_5.json
详细数据：reports/EXPERIMENTS.md；ASV 边界：reports/ASV_PROXY.md；录屏清单：reports/SUBMISSION_CHECKLIST.md。